

## *Introduction*

NN (perceptron) depuis (60-70?) aujourd'hui, bc d'applications, CNN Notre but est alors de comprendre et savoir comment mettre en oeuvre, NN qui s'exécute dans un temps raisonnable

# Table of contents

<b>1 What is a Neural Network?</b>	<b>2</b>
<b>2 What is a <i>Conolutional</i> Neural Network</b>	<b>2</b>
<b>3 Application</b>	<b>2</b>
<b>4 Conclusion</b>	<b>3</b>

## 1 What is a Neural Network?

Peut être vu comme une fonction qui prend des données (une image) en entrée et des classes (par exemple animal) en sortie. Bien évidemment, c'est une fonction très compliquée avec par exemple pour un image RGB,  $X$  inputs. D'où l'idée de la considérer comme une composition des fonctions facilement (linéaire) calculée par les ordi. La structure est la suivante: (input, neurones, weights, bias, output) <- ce sont les paramètres, des milliers! La question est donc comment trouver les paramètres, on parle alors de l'apprentissage du NN.

Apprentissage: Le principe est simple: On part d'une (dataset) déjà classifié, un ("training set") et on modifie le NN pour. Pour cela il faut introduire une fonction qui quantifie la précision du NN, "fonction perte" ou "cost function" notée  $d$ . C'est une fonction qui prend comme argument le résultat du NN noté  $y_{\text{tilde}}$  et le compare avec le résultat attendu  $y$ . Ici, on connaît le  $y$  correspondant à chaque input et on cherche à minimiser cette fonction perte en ajustant les paramètres ( $w, b$ ). L'apprentissage peut donc être vu comme un problème d'optimisation ... (Pour représenter), on montre le principe avec un algorithme d'optimisation classique, le gradient descent. En gros, le gradient de la  $f$  perte nous dit quelles paramètres faut-il augmenter et diminuer (et avec quelle poids) pour augmenter la  $f$  perte le plus possible. Or, on veut minimiser donc on prend le moins de ça. Permettant (pour le moment), que l'on sache calculer le gradient à chaque itération. Notre "stratégie" et donc d'initialiser le NN aléatoirement puis, on "suit" le gradient à chaque itération jusqu'à ce que on trouve un min. Il est important de noter que la fonction perte est en fait la somme de  $d$  de toutes les données. Finalement, on peut tester avec "testing set" ...

Réalisation: Fonction activation. Introduit de la non-linéarité, raisons d'optimisation: exemple: arctan. Softmax les sorties sont positives et la somme fait 1, peut être vu comme proba. Fonction Perte distance -> fonction perte.

Forward Backward Algorithme d'optimisation

## 2 What is a *Conolutional* Neural Network

CNN, en effet c'est très semblable à un NN classique: on ajoute des couches convolutionnelles. Il se trouve que ça donne des résultats impressionnants. Ici les filtres sont optimisés. Convolution Downsampling Backward

## 3 Application

Le problème MNIST (classique) greyscale (entre 0 et 1), une seule channel. "Par batch" Choix de fonctions: maxpool, ReLU plus simple que arctan et sigmoid, très utilisé en pratique. Adam adapté à optimisation par batch, plus sophistiqué que Stochastic Gradient Desc. Choix de structure: 2 couches conv, 8 filtres, stride = 1, batchsize = 2 couches denses (dims). Résultat / temps d'exécution. Modifications

## 4 Conclusion

...